

LAPORAN UJIAN AKHIR SEMESTER ANALISIS BIG DATA

Product Recommendation



Disusun Oleh :

Dian Ayu Fauziah (22031554011)

Shafa Nasywa Dhiya (22031554013)

Abdini Qolbi Sahlina (22031554015)

**UNIVERSITAS NEGERI SURABAYA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI S1 SAINS DATA
2025**

RINGKASAN

Project ini bertujuan untuk membangun sistem rekomendasi film menggunakan pendekatan *collaborative filtering* berbasis algoritma Alternating Least Squares (ALS). Dataset yang digunakan adalah MovieLens 20M Dataset, yang berisi lebih dari 20 juta data rating film oleh pengguna. Dataset ini dipilih karena memiliki skala besar, struktur interaksi user–item yang jelas, serta banyak digunakan dalam penelitian sistem rekomendasi.

Berdasarkan hasil *exploratory data analysis* (EDA), ditemukan bahwa data memiliki tingkat sparsity yang tinggi dengan distribusi interaksi bersifat *long-tail*, di mana sebagian besar pengguna dan film hanya memiliki sedikit rating. Kondisi ini menimbulkan tantangan dalam pemodelan sistem rekomendasi karena dapat menyebabkan noise dan ketidakstabilan model. Oleh karena itu, tahap data preparation dan feature engineering menjadi krusial untuk memastikan data siap digunakan oleh model.

Tahap data preparation dilakukan dengan membersihkan data, menghapus duplikasi, serta memfilter pengguna dan film dengan interaksi yang sangat rendah untuk mengurangi sparsity ekstrem. Selanjutnya, feature engineering dilakukan dengan melakukan encoding user dan item ke dalam representasi numerik serta membangun matriks interaksi user–item dalam bentuk sparse matrix. Matriks ini kemudian digunakan sebagai input utama untuk model ALS. Hasil akhir dari project ini diharapkan mampu menghasilkan rekomendasi film yang relevan serta memberikan insight terkait karakteristik data dan keterbatasan sistem rekomendasi, khususnya pada permasalahan *cold-start*.

BAB I ANALISIS DATA

1.1 Deskripsi Dataset

Dataset yang digunakan dalam penelitian ini adalah MovieLens 20M Dataset, yang berisi data rating film yang diberikan oleh pengguna. Dataset ini mencakup lebih dari 20 juta interaksi rating yang diberikan oleh lebih dari 100 ribu pengguna terhadap puluhan ribu film. Setiap entri data merepresentasikan satu interaksi antara pengguna dan film, yang terdiri dari atribut `userId`, `movieId`, `rating`, dan `timestamp`.

Dataset ini dipilih karena memiliki skala besar, struktur data yang jelas, serta banyak digunakan dalam penelitian sistem rekomendasi. Selain itu, dataset MovieLens menyediakan data interaksi eksplisit berupa rating numerik, yang sesuai untuk penerapan sistem rekomendasi berbasis *collaborative filtering*.

1.2 Gambaran Umum Dataset

	userId	movieId	rating
count	2.000026e+07	2.000026e+07	2.000026e+07

mean	6.904587e+04	9.041567e+03	3.525529e+00
std	4.003863e+04	1.978948e+04	1.051989e+00
min	1.000000e+00	1.000000e+00	5.000000e-01
25%	3.439500e+04	9.020000e+02	3.000000e+00
50%	6.914100e+04	2.167000e+03	3.500000e+00
75%	1.036370e+05	4.770000e+03	4.000000e+00
max	1.384930e+05	1.312620e+05	5.000000e+00

Dataset yang digunakan adalah MovieLens 20M Dataset, yang terdiri dari sekitar 20 juta data rating film. Dataset ini melibatkan lebih dari 138 ribu pengguna dan sekitar 131 ribu film, sehingga memiliki skala yang sangat besar dan beragam.

Setiap data merepresentasikan interaksi antara pengguna dan film, dengan atribut `userId`, `movieId`, dan `rating`. Nilai rating berada pada rentang 0.5 hingga 5.0 dengan interval 0.5. Berdasarkan statistik deskriptif, median rating sebesar 3.5, yang menunjukkan bahwa pengguna cenderung memberikan penilaian menengah hingga tinggi.

Dengan jumlah pengguna, film, dan interaksi yang besar, dataset ini memiliki karakteristik data yang sangat jarang (*sparse*) dan sesuai untuk penerapan sistem rekomendasi berbasis *collaborative filtering*, khususnya menggunakan metode *Alternating Least Squares (ALS)*.

1.3 Distribusi Rating

Analisis distribusi rating menunjukkan bahwa data tidak terdistribusi secara merata. Sebagian besar rating terkonsentrasi pada nilai 3.0, 3.5, dan 4.0, sementara rating rendah seperti 0.5 dan 1.0 jumlahnya relatif sedikit. Pola ini menunjukkan bahwa pengguna lebih sering memberikan rating positif dibandingkan negatif.

Distribusi rating yang condong ke nilai menengah–tinggi ini penting untuk diperhatikan karena model *Alternating Least Squares (ALS)* sensitif terhadap bias rating. Tanpa pemahaman terhadap distribusi ini, model berpotensi lebih merekomendasikan item populer dibandingkan item yang benar-benar relevan secara personal.

1.4 Aktivitas Pengguna (User Behavior)

Distribusi aktivitas pengguna memperlihatkan pola *long-tail* yang sangat jelas. Sebagian besar pengguna hanya memberikan sedikit rating, sementara hanya sebagian kecil pengguna yang sangat aktif dan memberikan ribuan rating. Untuk memperjelas pola ini, visualisasi dilakukan menggunakan skala logaritmik.

Kondisi ini mencerminkan situasi dunia nyata, di mana mayoritas pengguna bersifat pasif. Dari sudut pandang sistem rekomendasi, pengguna dengan jumlah rating yang sedikit dikategorikan sebagai *cold user*, yang menjadi tantangan tersendiri dalam proses personalisasi rekomendasi.

1.5 Popularitas Film (Item Activity)

Distribusi popularitas film juga menunjukkan pola long-tail yang serupa dengan aktivitas pengguna. Hanya sebagian kecil film yang menerima jumlah rating sangat besar, sedangkan mayoritas film hanya memiliki sedikit rating.

Fenomena ini mengindikasikan adanya popularitas bias, di mana film-film populer mendominasi interaksi pengguna. Dalam konteks sistem rekomendasi, kondisi ini dapat menyebabkan model cenderung merekomendasikan film populer dan mengabaikan film long-tail jika tidak ditangani dengan baik.

1.6 Sparsity pada User-Item Matrix

Dengan mempertimbangkan jumlah pengguna, jumlah film, dan total rating yang ada, tingkat sparsity pada matriks user-item mencapai sekitar 99.32%. Artinya, hampir seluruh kombinasi antara pengguna dan film tidak memiliki interaksi rating.

Tingkat sparsity yang sangat tinggi ini merupakan karakteristik umum pada sistem rekomendasi skala besar dan menjadi alasan utama dipilihnya metode collaborative filtering berbasis ALS, yang dirancang untuk bekerja secara efisien pada data yang sangat jarang (sparse).

1.7 Integrasi Rating pada Metadata Film

	title	rating
0	Jumanji (1995)	3.5
1	City of Lost Children, The (Cité des enfants p...	3.5
2	Twelve Monkeys (a.k.a. 12 Monkeys) (1995)	3.5
3	Seven (a.k.a. Se7en) (1995)	3.5
4	Usual Suspects, The (1995)	3.5

Untuk meningkatkan interpretabilitas hasil analisis, data rating digabungkan dengan metadata film menggunakan atribut movieId. Proses ini dapat membuat setiap interaksi rating dikaitkan dengan judul dan genre film yang bersangkutan.

Langkah ini penting karena hasil rekomendasi nantinya tidak hanya berupa identitas numerik film, tetapi juga dapat disajikan dalam bentuk judul film yang mudah dipahami oleh pengguna dan relevan untuk analisis bisnis.

1.8 Kualitas Film (Rata-Rata Rating vs Popularitas)

Analisis hubungan antara rata-rata rating film dan jumlah rating menunjukkan adanya perbedaan antara kualitas dan popularitas. Film dengan jumlah rating yang sedikit cenderung memiliki rata-rata rating yang sangat bervariasi, sedangkan film populer memiliki rata-rata rating yang lebih stabil, umumnya berada di kisaran 3 hingga 4.

Temuan ini menunjukkan bahwa film dengan rating tinggi belum tentu populer, dan sebaliknya. Hal ini menegaskan bahwa sistem rekomendasi berbasis collaborative filtering tidak hanya bergantung pada popularitas, tetapi pada kesesuaian preferensi pengguna.

1.9 Bias Pengguna dalam Pemberian Rating

Distribusi rata-rata rating per pengguna menunjukkan bahwa setiap pengguna memiliki kecenderungan penilaian yang berbeda. Sebagian pengguna cenderung memberikan rating tinggi secara konsisten, sementara sebagian lainnya lebih ketat dalam menilai film.

Perbedaan perilaku ini mencerminkan adanya user bias, yang secara implisit akan dipelajari oleh model ALS melalui representasi latent factor pengguna. Oleh karena itu, variasi ini menjadi komponen penting dalam personalisasi rekomendasi.

1.10 Film Paling Populer

	movieId	jumlah_rating	title	genres
0	296	67310	Pulp Fiction (1994)	Comedy Crime Drama Thriller
1	356	66172	Forrest Gump (1994)	Comedy Drama Romance War
2	318	63366	Shawshank Redemption, The (1994)	Crime Drama
3	593	63299	Silence of the Lambs, The (1991)	Crime Horror Thriller
4	480	59715	Jurassic Park (1993)	Action Adventure Sci-Fi Thriller
5	260	54502	Star Wars: Episode IV - A New Hope (1977)	Action Adventure Sci-Fi
6	110	53769	Braveheart (1995)	Action Drama War
7	589	52244	Terminator 2: Judgment Day (1991)	Action Sci-Fi
8	2571	51334	Matrix, The (1999)	Action Sci-Fi Thriller
9	527	50054	Schindler's List (1993)	Drama War

Berdasarkan jumlah rating, film-film yang paling populer didominasi oleh film klasik dan mainstream seperti *Pulp Fiction*, *Forrest Gump*, dan *The Shawshank Redemption*. Film-film ini menerima puluhan ribu rating, jauh lebih banyak dibandingkan film lainnya.

Hasil ini memperkuat temuan sebelumnya mengenai popularitas bias dan menunjukkan bahwa film populer cenderung mendominasi interaksi pengguna dalam dataset.

1.11 Pola Rating dari Waktu ke Waktu

Analisis temporal menunjukkan bahwa jumlah rating per tahun mengalami peningkatan signifikan pada awal hingga pertengahan tahun 2000-an, kemudian mengalami penurunan secara bertahap pada tahun-tahun berikutnya. Hal ini menunjukkan adanya perubahan tingkat aktivitas pengguna seiring waktu.

Meskipun model ALS yang digunakan dalam penelitian ini tidak mempertimbangkan faktor waktu, analisis temporal ini tetap penting untuk memberikan konteks historis terhadap data dan dapat menjadi dasar pengembangan model time-aware pada penelitian selanjutnya.

BAB II METODOLOGI

2.1 Alur Penelitian

Penelitian ini dilakukan melalui beberapa tahapan utama yang disusun secara sistematis untuk membangun sistem rekomendasi film berbasis *collaborative filtering*. Tahapan penelitian dimulai dari pemahaman dan analisis awal dataset, dilanjutkan dengan proses persiapan data dan rekayasa fitur, pemodelan sistem rekomendasi, evaluasi performa model, hingga penyusunan insight dan rekomendasi berbasis hasil analisis.

Alur penelitian secara umum meliputi tahapan *exploratory data analysis* (EDA), data preparation, feature engineering, pemodelan menggunakan algoritma Alternating Least Squares (ALS), serta evaluasi hasil rekomendasi. Setiap tahapan dirancang untuk saling mendukung agar sistem rekomendasi yang dihasilkan dapat bekerja secara efektif pada data berskala besar dan bersifat sparse.

2.2 Data Preparation dan Feature Engineering

2.3.1 Data Preparation

Tahap data preparation dilakukan untuk memastikan kualitas data sebelum digunakan dalam pemodelan. Proses ini diawali dengan pemeriksaan terhadap *missing value* dan data duplikat, serta pemilihan atribut yang relevan untuk sistem rekomendasi, yaitu *userId*, *movieId*, *rating*, dan *timestamp*.

Berdasarkan hasil EDA yang menunjukkan distribusi interaksi bersifat *long-tail* dan tingkat sparsity yang tinggi, dilakukan proses filtering terhadap pengguna dan film dengan jumlah interaksi yang sangat rendah. Dalam penelitian ini, hanya pengguna dan film yang memiliki minimal lima rating yang dipertahankan. Filtering ini bertujuan untuk mengurangi noise dan meningkatkan stabilitas model dengan menghilangkan interaksi yang terlalu jarang dan tidak representatif.

Setelah proses filtering, dilakukan evaluasi ulang terhadap jumlah pengguna, jumlah film, dan tingkat sparsity untuk memastikan bahwa data hasil persiapan memiliki struktur yang lebih seimbang dan siap digunakan pada tahap pemodelan.

2.3.2 Feature Engineering

Pada sistem rekomendasi berbasis *collaborative filtering*, feature engineering tidak berfokus pada penambahan atribut baru, melainkan pada transformasi struktur data interaksi. Oleh karena itu, tahap feature engineering dilakukan dengan melakukan encoding `userId` dan `movieId` ke dalam representasi numerik berupa indeks.

Transformasi ini diperlukan karena algoritma Alternating Least Squares (ALS) bekerja pada matriks numerik dan tidak dapat memproses identifier dalam bentuk ID asli. Selain itu, dibuat pula mapping antara indeks numerik dan ID asli untuk menjaga interpretabilitas hasil rekomendasi, sehingga hasil keluaran model dapat dikaitkan kembali dengan informasi film yang relevan.

Sebagai output akhir dari tahap ini, dibangun matriks interaksi user-item dalam bentuk *sparse matrix*. Matriks ini merepresentasikan hubungan antara pengguna dan film berdasarkan nilai rating, serta digunakan sebagai input utama pada tahap pemodelan sistem rekomendasi.

2.4 Pemodelan Sistem Rekomendasi

Tahap pemodelan dilakukan dengan menerapkan algoritma Alternating Least Squares (ALS) sebagai model utama dalam sistem rekomendasi. ALS dipilih karena kemampuannya dalam menangani data berskala besar dan bersifat sparse secara efisien. Model ini bekerja dengan melakukan dekomposisi matriks interaksi user-item menjadi dua matriks laten, yaitu matriks representasi pengguna dan matriks representasi item.

Selain model utama, digunakan pula model pembanding berbasis popularitas (*popularity-based recommendation*), di mana rekomendasi diberikan berdasarkan film dengan jumlah rating tertinggi. Model pembanding ini digunakan sebagai baseline untuk mengevaluasi efektivitas model ALS dalam menghasilkan rekomendasi yang lebih personal.

2.5 Evaluasi Model

Evaluasi model dilakukan untuk mengukur kemampuan sistem rekomendasi dalam menghasilkan rekomendasi yang relevan. Metode evaluasi yang digunakan mencakup metrik berbasis Top-N recommendation, seperti *Hit Rate@K*. Evaluasi dilakukan dengan membandingkan performa model ALS terhadap model pembanding berbasis popularitas.

Selain evaluasi kuantitatif, dilakukan pula analisis kualitatif terhadap hasil rekomendasi untuk memahami pola rekomendasi yang dihasilkan serta mengidentifikasi keterbatasan sistem, khususnya pada permasalahan *cold-start* untuk pengguna atau film baru.

BAB III HASIL DAN EVALUASI

3.1 Hasil Pemodelan Sistem Rekomendasi

Pada penelitian ini, dilakukan pemodelan sistem rekomendasi menggunakan dua pendekatan, yaitu model utama berbasis *collaborative filtering* menggunakan algoritma *Alternating Least Squares* (ALS) dan model pembanding berbasis popularitas (*most popular recommendation*). Evaluasi dilakukan menggunakan metrik *Precision@10* dan *Recall@10* dengan jumlah pengguna yang dievaluasi sebanyak 2.000 pengguna.

Hasil evaluasi untuk masing-masing model ditunjukkan sebagai berikut:

	Precision@10	Recall@10
Model ALS	0,00035	0,00015
Model Most Popular	0,08105	0,04830

Hasil tersebut menunjukkan adanya perbedaan performa yang cukup signifikan antara kedua pendekatan yang digunakan.

BAB IV

HASIL DAN INSIGHT REKOMENDASI

Hasil evaluasi sistem rekomendasi menunjukkan bahwa model berbasis popularitas (*most popular*) memiliki performa kuantitatif yang lebih tinggi dibandingkan model *collaborative filtering* berbasis Alternating Least Squares (ALS). Model ALS menghasilkan nilai *Precision@10* sebesar 0,00035 dan *Recall@10* sebesar 0,00015, sedangkan model *most popular* memperoleh *Precision@10* sebesar 0,08105 dan *Recall@10* sebesar 0,04830. Perbedaan ini dipengaruhi oleh karakteristik dataset *MovieLens* yang sangat sparse dan memiliki distribusi interaksi *long-tail*, sehingga film-film populer memiliki peluang lebih besar untuk sesuai dengan interaksi pengguna pada data uji.

Meskipun demikian, keunggulan model *most popular* bersifat global dan tidak mempertimbangkan preferensi individual pengguna, sehingga tingkat personalisasi rekomendasi rendah. Sebaliknya, model ALS mampu menghasilkan rekomendasi yang lebih personal dengan memanfaatkan pola laten interaksi pengguna dan item, meskipun performa metriknya lebih rendah akibat keterbatasan data dan tidak dilakukan *hyperparameter tuning* kompleks. Temuan ini menunjukkan adanya *trade-off* antara akurasi berbasis popularitas dan personalisasi, sehingga pendekatan hibrida direkomendasikan untuk menghasilkan sistem rekomendasi yang lebih seimbang dan efektif.

Link Code:

https://colab.research.google.com/drive/1n-pzKV8B4GtWVGUo5n1m_8eb1sWR458a?usp=sharing

Link Dataset:

<https://www.kaggle.com/datasets/grouplens/movielens-20m-dataset?resource=download>